#### Trabalho A2 - Parte 1 - Yonathan Rabinovici Gherman

Base de Dados escolhida: https://www.kaggle.com/datasets/iamsouravbanerjee/software-professional-salaries-2022

Essa base de dados refere-se a profissionais da Índia, e os salário são expressos na moeda local.

#### Análises Unidimensionais


```
# Importando as bibliotecas
library(tidyverse)
## -- Attaching packages ------ tidyverse 1.3.1 --
## v ggplot2 3.3.6 v purr 0.3.4
## v tibble 3.1.7 v dplyr 1.0.9
## v tidyr 1.2.0 v stringr 1.4.0
## v readr 2.1.2 v forcats 0.5.1
## -- Conflicts ----- tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag() masks stats::lag()
#qetwd()
# Importando a base de dados e verificando os tipos de variáveis(int, dbl, char...)
base_dados <- read.csv("salario_tech.csv")</pre>
glimpse(base_dados)
## Rows: 22,770
## Columns: 8
## $ Rating
                      <dbl> 3.8, 4.5, 4.0, 3.8, 4.4, 4.2, 3.7, 3.1, 3.7, 3.6, 3.~
## $ Company.Name
                      <chr> "Sasken", "Advanced Millennium Technologies", "Unaca~
## $ Job.Title
                      <chr> "Android Developer", "Android Developer", "Android D~
                      <int> 400000, 400000, 1000000, 300000, 600000, 100000, 192~
## $ Salary
## $ Salaries.Reported <int> 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 3, 2, 2, 2, 2, 2, 2, 2
                      <chr> "Bangalore", "Bangalore", "Bangalore", "Bangalore", ~
## $ Location
## $ Employment.Status <chr> "Full Time", "Full Time", "Full Time", "Full Time", ~
## $ Job.Roles
                      <chr> "Android", "Android", "Android", "Android", "Android"
# Garantindo que todas as palvras fiquem em maiúsculo para não haver diferenciação de um mesmo dado
base_dados <- base_dados %>% mutate_if(is.character, toupper)
```

#### Salário


```
# Salário
# Análise da média, mediana, quartil, mínimo e máximo dos salários na moeda Indian Rupee -
summary(base_dados$Salary)
```

```
## Min. 1st Qu. Median Mean 3rd Qu. Max.
## 2112 300000 500000 695387 900000 90000000
```


# Criação do box plot de salários limitado a 1800000 para que os outliers(que estão presentes em grande ggplot(base\_dados, aes(y = Salary, x="")) + geom\_boxplot() + coord\_cartesian(ylim=c(0,1800000))




```
# Caso não houvesse limitação ele seria visto assim:
ggplot(base_dados, aes(y = Salary, x="")) + geom_boxplot()
```



```
# Porém, ao colocá-lo em escala lograítmica é possívelo vê-lo sem ter de limitar ggplot(base_dados, aes(y = Salary, x="")) + geom_boxplot() + scale_y_continuous(trans = 'log2')
```




```
# Grande parte dos outliers concentram-se nesse limite
ggplot(base_dados, aes(y = Salary, x="")) + geom_boxplot() + coord_cartesian(ylim=c(0,10000000))
```



```
# Histograma dos salários
ggplot(base_dados, aes(Salary)) + geom_histogram(binwidth = 900000, boundary = 900000) + coord_cartesia
scale_y_continuous(trans = 'log2')
```

- ## Warning: Transformation introduced infinite values in continuous y-axis
- ## Warning: Removed 87 rows containing missing values (geom\_bar).




# Avaliação da Empresa

```
# Avaliação da Empresa
# Análise da média, mediana, quartil, mínimo e máximo das avaliações dadas as empresas
summary(base_dados$Rating)


## Min. 1st Qu. Median Mean 3rd Qu. Max.
## 1.000 3.700 3.900 3.918 4.200 5.000

# Box plot das avaliações
ggplot(base_dados, aes(y=Rating, x="")) + geom_boxplot()
```



```
# Histograma das avaliações
ggplot(base_dados, aes(Rating)) + geom_histogram()
```

## `stat\_bin()` using `bins = 30`. Pick better value with `binwidth`.



# TOP 30 Profissões com mais profissionais


contagem <- base\_dados %>% count(Job.Title)

```
colnames(contagem)[1] <- "JobTitle"
p <-contagem %>% arrange(desc(n))
p <- p %>% top_n(n=30)

## Selecting by n

colnames(p)[2] <- "numero_profissionais"


p <- ggplot(data = p, aes(x=reorder(JobTitle, +numero_profissionais), y=numero_profissionais)) + geom_b
p +coord_flip()</pre>
```



#### Frequência dos tipos de contrato/Status de emprego

```
#Status de Emprego
p <- base_dados %>% count(Employment.Status)
tibble(p)
## # A tibble: 4 x 2
     Employment.Status
##
                            n
     <chr>>
                        <int>
## 1 CONTRACTOR
                          548
## 2 FULL TIME
                        20083
## 3 INTERN
                         2106
## 4 TRAINEE
                           33
pie(x=p$n, labels=p$Employment.Status, main = "Tipo de emprego")
```

# Tipo de emprego



## Análise Bidimensional

Quantidade de pessoas em uma área x média de salários nessa área


```
# PARTE 2 - Análise Bidimensional
#Análise entre Média Salarial e o nome da posição ocupada
p <- base_dados
base <- as_tibble(p)
p <- base %>% count(Job.Title)
sal <- base %>% group_by(Job.Title) %>% summarise(media=mean(Salary))
dado <- bind_cols(sal,p)

## New names:
## * `Job.Title` -> `Job.Title...1`
## * `Job.Title` -> `Job.Title...3`


dado <- dado[,-c(3)]
dado <- dado %>% arrange(desc(n))
colnames(dado)[2] <- "media_salarial"
colnames(dado)[3] <- "qtd_profissionais"
dado</pre>
```

```
## # A tibble: 1,080 x 3
      Job.Title...1
##
                                                   media_salarial qtd_profissionais
##
                                                            <dbl>
## 1 SOFTWARE DEVELOPMENT ENGINEER
                                                          781570.
                                                                                2351
                                                                                2029
##
   2 ANDROID DEVELOPER
                                                          508106.
## 3 SOFTWARE DEVELOPMENT ENGINEER (SDE)
                                                          885917.
                                                                                1614
## 4 FRONT END DEVELOPER
                                                          579359.
                                                                                1412
## 5 TEST ENGINEER
                                                          502066.
                                                                                1314
## 6 WEB DEVELOPER
                                                          439625.
                                                                                 853
## 7 SOFTWARE DEVELOPMENT ENGINEER - INTERN
                                                          399219.
                                                                                771
## 8 SOFTWARE DEVELOPMENT ENGINEER IN TEST (SDET)
                                                          777185.
                                                                                766
## 9 BACKEND DEVELOPER
                                                          663234.
                                                                                 534
## 10 PYTHON DEVELOPER
                                                          487069.
                                                                                 485
## # ... with 1,070 more rows
```


ggplot(dado, aes(x=qtd\_profissionais, y=media\_salarial)) + geom\_point() + scale\_y\_continuous(trans = '




ggplot(dado, aes(x=media\_salarial, y=qtd\_profissionais)) + geom\_point() + scale\_x\_continuous(trans = '



```
ggplot(dado, aes(x=media_salarial, y=qtd_profissionais)) + geom_point() + scale_x_continuous(trans = '
## `geom_smooth()` using method = 'gam' and formula 'y ~ s(x, bs = "cs")'
```




 $\verb|ggplot(dado, aes(x=qtd_profissionais, y=media_salarial))| + \verb|geom_line()| + \verb|geom_point()| + | scale_y_conting(x=qtd_profissionais, y=media_salarial)| + | scale_y_conting(x=qtd_pro$ 



```
# Teste de Correlação
cor.test(x= dado$qtd_profissionais, y= dado$media_salarial, method = "pearson")
##
   Pearson's product-moment correlation
##
##
## data: dado$qtd_profissionais and dado$media_salarial
## t = -0.98447, df = 1078, p-value = 0.3251
\#\# alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
   -0.08946282 0.02973420
## sample estimates:
           cor
## -0.02997086
#cor = 1: Correlação perfeita positiva entre as duas variáveis.
#cor = 0: Não existe correlação linear, a correlação deve ser investigada por outros métodos.
#cor = −1: Correlação perfeita negativa entre as duas variáveis.
```

Tipo de contrato/status de emprego x média salarial

```
p <- base_dados
base <- as_tibble(p)</pre>
p <- base %>% count(Employment.Status)
sal <- base %>% group_by(Employment.Status) %>% summarise(media=mean(Salary))
dado <- bind_cols(sal,p)</pre>
## New names:
## * `Employment.Status` -> `Employment.Status...1`
## * `Employment.Status` -> `Employment.Status...3`
dado \leftarrow dado[,-c(3)]
colnames(dado)[1] <- "tipo_contrato"</pre>
colnames(dado)[2] <- "media_salarial"</pre>
colnames(dado)[3] <- "qtd_profissionais"</pre>
dado <- dado %>% arrange(desc(media_salarial))
dado
## # A tibble: 4 x 3
    tipo_contrato media_salarial qtd_profissionais
##
     <chr>
                             <dbl>
                                                <int>
## 1 FULL TIME
                           733332.
                                                20083
## 2 CONTRACTOR
                         627362.
                                                 548
## 3 INTERN
                                                 2106
                           357054.
## 4 TRAINEE
                           324303.
ggplot(dado, aes(y=media_salarial, x=tipo_contrato)) + geom_point(size=5) + scale_y_continuous(trans =
```




## Porcentagem dos tipos de contrato nas 5 cidades com mais profissionais(LEMBRE-SE: LEVE EM CONTA A UNIDADE DO EIXO X)

```
# Porcentagem dos tipos de contrato nas 5 cidades com mais profissionais
p <- base dados
base <- as_tibble(p)</pre>
# BANGALORE
status_contractor_bangalore <- (nrow(base %>% filter(str_detect(Location, "BANGALORE")) %>%
                                      filter(str_detect(Employment.Status, "CONTRACTOR"))))/nrow(base %>
status_full_bangalore <- (nrow(base %>% filter(str_detect(Location, "BANGALORE")) %>%
                                 filter(str_detect(Employment.Status, "FULL TIME"))))/nrow(base %>%
                                                                                              filter(str
status_intern_bangalore <- (nrow(base %>% filter(str_detect(Location, "BANGALORE")) %>%
                                 filter(str_detect(Employment.Status,"INTERN"))))/nrow(base %>%
                                                                                              filter(str
status_trainee_bangalore <- (nrow(base %>% filter(str_detect(Location, "BANGALORE")) %>%
                                   filter(str_detect(Employment.Status,"TRAINEE"))))/nrow(base %>%
                                                                                             filter(str_d
#CHENNAI
status_contractor_chennai <- (nrow(base %>% filter(str_detect(Location, "CHENNAI")) %>%
```

```
filter(str_detect(Employment.Status,"CONTRACTOR"))))/nrow(base %>%
                                                                                            filter(str d
status_full_chennai <- (nrow(base %>% filter(str_detect(Location, "CHENNAI")) %>%
                                     filter(str_detect(Employment.Status, "FULL TIME"))))/nrow(base %>%
status_intern_chennai <- (nrow(base %>% filter(str_detect(Location, "CHENNAI")) %>%
                                     filter(str detect(Employment.Status, "INTERN"))))/nrow(base %>%
                                                                                                   filter
status_trainee_chennai <- (nrow(base %% filter(str_detect(Location, "CHENNAI")) %>%
                                     filter(str_detect(Employment.Status, "TRAINEE"))))/nrow(base %>%
                                                                                                   filter
#HYDERABAD
status_contractor_hyderabad <- (nrow(base %>% filter(str_detect(Location, "HYDERABAD")) %>%
                                     filter(str_detect(Employment.Status, "CONTRACTOR"))))/nrow(base %>%
                                                                                                   filter
status_intern_hyderabad <- (nrow(base %>% filter(str_detect(Location, "HYDERABAD")) %>%
                                       filter(str_detect(Employment.Status,"INTERN"))))/nrow(base %>%
                                                                                                     filt
status_full_hyderabad <- (nrow(base %>% filter(str_detect(Location, "HYDERABAD")) %>%
                                       filter(str detect(Employment.Status, "FULL TIME"))))/nrow(base %>
                                                                                                     filt
status_trainee_hyderabad <- (nrow(base %>% filter(str_detect(Location, "HYDERABAD")) %>%
                                       filter(str_detect(Employment.Status, "TRAINEE"))))/nrow(base %>%
                                                                                                     filt
#NEW DELHI
status_contractor_new <- (nrow(base %>% filter(str_detect(Location, "NEW DELHI")) %>%
                                       filter(str_detect(Employment.Status, "CONTRACTOR"))))/nrow(base %
                                                                                                     filt
status_intern_new <- (nrow(base %>% filter(str_detect(Location, "NEW DELHI")) %>%
                                    filter(str_detect(Employment.Status,"INTERN"))))/nrow(base %>%
                                                                                                 filter(
status_full_new <- (nrow(base %>% filter(str_detect(Location, "NEW DELHI")) %>%
                                filter(str_detect(Employment.Status, "FULL TIME"))))/nrow(base %>%
                                                                                         filter(str_dete
status_trainee_new <- (nrow(base %>% filter(str_detect(Location, "NEW DELHI")) %>%
                                filter(str_detect(Employment.Status, "TRAINEE"))))/nrow(base %>%
                                                                                         filter(str_dete
#PUNE
status_contractor_pune <- (nrow(base %>% filter(str_detect(Location, "PUNE")) %>%
                                 filter(str_detect(Employment.Status, "CONTRACTOR"))))/nrow(base %>%
```


#### Porcentagem de CONTRACTOR nas 5 cidades com mais profissionais

```
#CONTRACTOR
p <- base_dados
base <- as_tibble(p)
p <- base %>% count(Location)
p <- slice(p, c(1,2,3,9,10))
p_contractor <- p[,-c(2)]
arr <- c(status_contractor_bangalore, status_contractor_chennai, status_contractor_hyderabad, status_contractor <-data.frame(arr)
df_contractor <- bind_cols(p_contractor,df_contractor)
colnames(df_contractor)[2] <- "porcentagem_contractor"
ggplot(df_contractor, aes(Location, porcentagem_contractor)) + geom_bar(stat="identity") + coord_flip()</pre>
```




# Porcentagem de FULL TIME nas 5 cidades com mais profissionais

```
#FULL TIME
arr <- c(status_full_bangalore, status_full_chennai, status_full_hyderabad, status_full_new, status_ful
df_full <-data.frame(arr)
df_full <- bind_cols(p_contractor,df_full)
colnames(df_full)[2] <- "porcentagem_full"
ggplot(df_full, aes(Location, porcentagem_full)) + geom_bar(stat="identity") + coord_flip()</pre>
```




# Porcentagem de INTERN nas 5 cidades com mais profissionais

```
# INTERN
arr <- c(status_intern_bangalore, status_intern_chennai, status_intern_hyderabad, status_intern_new, st
df_intern <-data.frame(arr)
df_intern <- bind_cols(p_contractor,df_intern)
colnames(df_intern)[2] <- "porcentagem_intern"
ggplot(df_intern, aes(Location, porcentagem_intern)) + geom_bar(stat="identity") + coord_flip()</pre>
```



# Porcentagem de TRAINEE nas 5 cidades com mais profissionais

```
# TRAINEE
arr <- c(status_trainee_bangalore, status_trainee_chennai, status_trainee_hyderabad, status_trainee_new
df_trainee <-data.frame(arr)
df_trainee <- bind_cols(p_contractor,df_trainee)
colnames(df_trainee)[2] <- "porcentagem_trainee"
ggplot(df_trainee, aes(Location, porcentagem_trainee)) + geom_bar(stat="identity") + coord_flip()</pre>
```



Observa-se constância nas empresas (que poderia ter sido observada no gráfico de pizza das análises unidimensionais, porém aqui é demonstrado de forma mais detalhada): elas possuem mais contratos Full Time, em seguida Intern, Contractor e Trainee

A partir dessa análise é possível chegar em conlusões como: cidades que dão mais chance de pessoas iniciarem como trainee, por exemplo, Chennai. Mas, é importante considerar outras questões, como espaço amostral daquela cidade, entre outros.